

ML Projet

Isai Gordeev

École Polytechnique

20 avril 2023

Plan

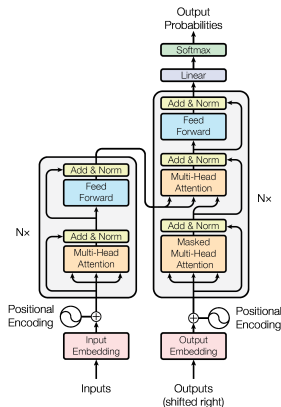

- 1 ML ou pas ?
 - Oui, je suis sûr et alors quoi ?
- 2 Architecture
- 3 Metaparamètres
- 4 Données
- 5 Apprentissage
- 6 Réglage
- 7 Résultat
- 8 Bilan

ML ou pas ?

Vous êtes sûr en emploi de ML ?
Votre problème peut être résolu **algorithmiquement**

Architecture

- Réseau neuronal convolutif (CNN) – le traitement des images
- Réseaux antagonistes génératifs (GAN) - la génération des objets
- Transformer – l'architecture d'utilisation générale



Metaparamètres

- Le réseau

- ▶ Les fonctions d'activations
- ▶ Les couches
- ▶ Autres

- Vraisemblance

- ▶ La fonction de perte $L(W, y, \hat{y})$
- ▶ Régularization
- ▶ Autres

Activation Functions

Sigmoid
 $\sigma(x) = \frac{1}{1+e^{-x}}$



tanh
 $\tanh(x)$



ReLU
 $\max(0, x)$




Leaky ReLU
 $\max(0.1x, x)$



Maxout
 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$



L1 Regularization

$$\text{Cost} = \sum_{i=0}^N (y_i - \sum_{j=0}^M x_{ij} W_j)^2 + \lambda \sum_{j=0}^M |W_j|$$

L2 Regularization

$$\text{Cost} = \underbrace{\sum_{i=0}^N (y_i - \sum_{j=0}^M x_{ij} W_j)^2}_{\text{Loss function}} + \lambda \underbrace{\sum_{j=0}^M W_j^2}_{\text{Regularization Term}}$$

- Il faut collecter les données (ou notre tensor X)
- Il faut éviter les attributs dépendants
- Pour l'apprentissage 80% de données
- Pour la validation 20% de données

Par exemple on a n image de chat noir
Il faut dire si une image contient un chat noir

1 Rétropropagation

$$\delta^1 = (f^1)' \circ (W^2)^T \cdot (f^2)' \circ \dots \circ (W^{L-1})^T \cdot (f^{L-1})' \circ (W^L)^T \cdot (f^L)'$$

$$\delta^2 = (f^2)' \circ \dots \circ (W^{L-1})^T \cdot (f^{L-1})' \circ (W^L)^T \cdot (f^L)' \circ \nabla_{a^L} C$$

$$\vdots$$

$$\delta^{L-1} = (f^{L-1})' \circ (W^L)^T \cdot (f^L)' \circ \nabla_{a^L} C$$


$$\delta^L = (f^L)' \circ \nabla_{a^L} C,$$

2 Algorithme du gradient stochastique

$$W^i = W^i - \lambda \nabla L(W, y, \hat{y})_{W^i} = W^i - \lambda \delta_W^i$$

$$L(W, y, \hat{y}) = \arg(\min_X L(W, y, \hat{y}))$$


On maintient le modèle en répétant les étapes 3 - 5 (2 - 5)



On a obtenu la fonction f permettant prévoir pour un élément X_i de X son caractéristique et la façon de la généraliser et maintenir

$$f(X_i) = y_i$$

Bilan



Activation Functions

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

tanh

$$\tanh(x)$$

ReLU

$$\max(0, x)$$

Rétropropagation

$$\delta^1 = (f^1)' \circ (W^2)^T \cdot (f^2)' \circ \dots \circ (W^{L-1})^T \cdot (f^{L-1})' \circ (W^L)^T \cdot (f^L)' \circ \nabla_{\mathcal{L}} C$$

$$\delta^2 = (f^2)' \circ \dots \circ (W^{L-1})^T \cdot (f^{L-1})' \circ (W^L)^T \cdot (f^L)' \circ \nabla_{\mathcal{L}} C$$

⋮

$$\delta^{L-1} = (f^{L-1})' \circ (W^L)^T \cdot (f^L)' \circ \nabla_{\mathcal{L}} C$$

$$\delta^L = (f^L)' \circ \nabla_{\mathcal{L}} C$$

Algorithme du gradient stochastique

$$W^i = W^i - \lambda \nabla L(W, y, \hat{y})_{W^i} = W^i - \lambda \delta^i_{W^i}$$

$$L(W, y, \hat{y}) = \arg(\min_X L(W, y, \hat{y}))$$





Figure 12.2 Deep network architecture with multiple layers.



Merci pour votre attention